



機能アノテーションと GO解析

基礎生物学研究所
超階層生物学センター
データ統合解析室
内山 郁夫


RNA-seq解析結果の解釈



解析の流れ



遺伝子アノテーション 基本戦略



遺伝子アノテーション

- 遺伝子構造の予測

- 通常の遺伝子構造予測では、イントロン-エクソン構造の予測が必要だが、RNA-seq解析では、すでにmRNA配列が得られているので、これは不要。ただし、配列中のタンパク質をコードする領域(CDS)を予測する必要がある。
- blastxなどのツールを用いると、CDS予測をせずに、全読枠を翻訳してホモロジー検索を実行することも可能。ただし時間がかかる。

- 遺伝子機能の予測

- ホモロジー検索、もしくはモチーフ検索を行い、ヒットした類似配列もしくはモチーフの機能に基づいて機能を推定する。

TransDecoder

- 転写配列中のコード領域を予測するツール。もともとTrinityに付属のツールとして開発されたが、現在は独立のツールとして公開されている。

Home

Brian Haas edited this page on 3 May · 12 revisions

TransDecoder (Find Coding Regions Within Transcripts)

TransDecoder identifies candidate coding regions within transcript sequences, such as those generated by de novo RNA-Seq transcript assembly using Trinity, or constructed based on RNA-Seq alignments to the genome using Tophat and Cufflinks.

TransDecoder identifies likely coding sequences based on the following criteria:

- a minimum length open reading frame (ORF) is found in a transcript sequence
- a log-likelihood score similar to what is computed by the [GeneID](#) software is > 0 .
- the above coding score is greatest when the ORF is scored in the 1st reading frame as compared to scores in the other 2 forward reading frames.
- if a candidate ORF is found fully encapsulated by the coordinates of another candidate ORF, the longer one is reported. However, a single transcript can report multiple ORFs (allowing for operons, chimeras, etc).
- a PSSM is built/trained/used to refine the start codon prediction.
- **optional** the putative peptide has a match to a Pfam domain above the noise cutoff score.

Obtaining TransDecoder

The latest release of TransDecoder can be found [here](#).

Running TransDecoder

Note, TransDecoder is now available on [Galaxy](#) [usegalaxy.eu](#)

Predicting coding regions from a transcript fasta file

The 'TransDecoder' utility is run on a fasta file containing the target transcript sequences. The simplest usage is as follows:

Step 1: extract the long open reading frames

```
TransDecoder.LongOrfs -t target_transcripts.fasta
```

Pages 1

Home

- TransDecoder (Find Coding Regions Within Transcripts)
- Obtaining TransDecoder
- Running TransDecoder
 - Predicting coding regions from a transcript fasta file
 - Step 1: extract the long open reading frames
 - Step 2: (optional)
 - Step 3: predict the likely coding regions
 - Starting from a genome-based transcript structure GTF file (eg. cufflinks or stringtie)
- Sample data and execution
- Output files explained
- Including homology searches as ORF retention criteria
 - BlastP Search
 - Pfam Search
- Integrating the Blast and Pfam search results into coding region selection
- Viewing the ORF predictions in a genome browser
 - Viewing ORFs on target transcripts
 - Viewing ORFs in the context of the transcript structures on the genome
- Technical Support and Project Announcements

TransDecoderの実行

クエリ配列： seqfile.fa

- 長いORFを抽出する (≥ 100 aa)

```
% TransDecoder.LongOrfs -t seqfile.fa
```

- 長さ上位500のORFを使って、コード領域の確率モデルパラメータを推定し、それを用いてコード領域を予測する


```
% TransDecoder.Predict -t seqfile.fa
```

出力ファイル：seqfile.fa.transdecoder.???


pep: アミノ酸配列、 cds: 塩基配列、 gff3: GFF形式の遺伝子座標

ホモロジーに基づく機能推定

ホモロジー検索



モチーフ／プロファイル検索



ホモロジー検索とアノテーション

ヘモグロビン
β鎖

||
オーソログ

他の
グロビン族
(パラログ)

非相同
蛋白質

Sequences producing significant alignments:		Score	E
ue		(bits)	Val
ベストヒット		E-valueが低い	
sp:HBB_HUMAN	HEMOGLOBIN BETA CHAIN.	306	1e-83
sp:HBB_GORGO	HEMOGLOBIN BETA CHAIN.	305	3e-83
sp:HBB2_PANLE	HEMOGLOBIN BETA-2 CHAIN.	302	2e-82
sp:HBB_HYLLA	HEMOGLOBIN BETA CHAIN.	300	6e-82
sp:HBB_PREEN	HEMOGLOBIN BETA CHAIN.	298	4e-81
sp:HBB_COLPO	HEMOGLOBIN BETA CHAIN.	295	2e-80
sp:HBB_CERAE	HEMOGLOBIN BETA CHAIN.	295	3e-80
sp:HBB_MACFU	HEMOGLOBIN BETA CHAIN.	293	1e-79
sp:HBB_COLBA	HEMOGLOBIN BETA CHAIN.	293	1e-79
sp:MYG_BALAC	MYOGLOBIN.	49	5e-06
sp:MYG_MEGNO	MYOGLOBIN.	48	8e-06
sp:MYG_ESCGI	MYOGLOBIN.	48	1e-05
sp:MYG_BALPH	MYOGLOBIN.	47	2e-05
sp:MYG_ZIPCA	MYOGLOBIN.	46	4e-05
sp:GLB1_ARTSX	GLOBIN E1, EXTRACELLULAR.	45	9e-05
sp:GLP2_GLYDI	GLOBIN, POLYMERIC COMPONENT P2.	42	6e-04
sp:GLP1_GLYDI	GLOBIN, MAJOR POLYMERIC COMPONENT P1.	41	8e-04
sp:HBAZ_MACEU	HEMOGLOBIN ZETA CHAIN (FRAGMENTS).	39	0.005
sp:GLP3_GLYDI	GLOBIN, POLYMERIC COMPONENT P3.	38	0.009
sp:LGB2_PEA	LEGHEMOGLOBIN II.	36	0.035
sp:LGB1_PEA	LEGHEMOGLOBIN I.	35	0.079
sp:LGB2_SESRO	LEGHEMOGLOBIN 2.	34	0.18
sp:HBP_CANLI	LEGHEMOGLOBIN.	32	0.40
sp:LGB1_VICFA	LEGHEMOGLOBIN I.	32	0.53
sp:LACG_LACCA	6-PHOSPHO-BETA-GALACTOSIDASE (EC 3.2.1.85) (BETA-...	32	0.53
sp:LGB3_SESRO	LEGHEMOGLOBIN 3.	31	0.90
sp:LGBA_PHAVU	LEGHEMOGLOBIN A.	31	0.90
sp:HMPA_BACSU	FLAVOHEMOPROTEIN (HAEMOGLOBIN-LIKE PROTEIN) (FLAV...	31	1.2


E-value
非相同配列を
間違っ拾って
しまう個数の
期待値

統計的に
有意な類似性


微妙な類似性

統計的に
有意でない

オーソログとパラログ



双方向ベストヒットによるオーソログの推定



BLAST 検索の実行

```
# 配列ファイルdb.faに検索用のインデックスを作成。データベース名 dbnameで出力。
% makeblastdb -in db.fa -dbtype prot -parse_seqids -out dbname
# 作成したデータベースに対して、query.faをクエリとした検索の実行。
# タブ区切り形式 (outfmt 6)で、標準の形式にタイトル行を付加して、上位10ヒットを出力。
% blastp -query query.fa -db dbname -evalue 0.001
      -outfmt "6 std stitle" -max_target_seqs 10 -num_threads 8 > blastout.tab
```

1. query	2. subject (database)	3. %identity	4. align-len	5. mismatch	6. gap_open	7. q_start	8. q_end	9. s_start	10. s_end	11. evalue	12. bit-score	13. title
DI49_1142	NP_009669.1	93.421	228	15	0	8	235	4	231	9.83e-162	444	ADP-ribose diphosphatase
DI49_2764	NP_012252.1	88.604	1404	156	3	1	1401	1	1403	0.0	2560	ATP-binding cassette multid
DI49_2764	NP_014654.1	67.521	1404	426	8	1	1393	1	1385	0.0	1943	ATP-binding cassette sterol
DI49_2764	NP_014468.3	37.097	1364	721	26	51	1356	48	1332	0.0	873	ATP-binding cassette multid
DI49_2764	NP_014468.3	22.911	694	426	27	762	1402	43	680	2.40e-27	119	ATP-binding cassette multid
DI49_2764	NP_014468.3	20.819	562	377	20	111	639	807	1333	3.47e-17	85.9	ATP-binding cassette multid
MSTRG.1000.1	NP_013901.1	68.702	1425	423	7	1	1416	1	1411	0.0	2005	Ecm5p [Saccharomyces cerevi
MSTRG.1000.1	NP_012653.1	34.177	79	51	1	485	562	384	462	5.68e-05	45.4	histone demethylase [Saccha
MSTRG.1000.1	NP_012653.1	27.523	109	73	3	637	743	487	591	5.54e-04	42.4	histone demethylase [Saccha
MSTRG.1000.3	NP_013901.1	68.702	1425	423	7	1	1416	1	1411	0.0	2005	Ecm5p [Saccharomyces cerevi
MSTRG.1000.3	NP_012653.1	34.177	79	51	1	485	562	384	462	5.68e-05	45.4	histone demethylase [Saccha
MSTRG.1000.3	NP_012653.1	27.523	109	73	3	637	743	487	591	5.54e-04	42.4	histone demethylase [Saccha

DIAMOND 超高速ホモロジー検索

インデックスの作成

```
% diamond makedb --in db.fa --db db
```

検索の実行

```
% diamond blastp --query query.fa --db db
--evaluate 0.001 --max-target-seqs 10
--outfmt 6 qseqid sseqid pident evalue bitscore stitle
--threads 4 --out diamondout.tab
```

1. query	2. subject (database)	3. %identity	4. evalue	5. bit-score	6. title
DI49_1142	NP_009669.1	93.4	2.5e-122	433.3	NP_009669.1 ADP-ribose diphosphatase [Saccharomyces cerevisiae S288C]
DI49_2764	NP_012252.1	88.7	0.0e+00	2499.2	NP_012252.1 ATP-binding cassette multidrug transporter PDR11 [Saccharomyces ce
DI49_2764	NP_014654.1	67.9	0.0e+00	1876.3	NP_014654.1 ATP-binding cassette sterol transporter AUS1 [Saccharomyces cerevi
DI49_2764	NP_014468.3	37.4	1.1e-236	815.8	NP_014468.3 ATP-binding cassette multidrug transporter PDR18 [Saccharomyces ce
DI49_2764	NP_010294.1	35.5	6.0e-232	800.0	NP_010294.1 ATP-binding cassette transporter SNQ2 [Saccharomyces cerevisiae S2
DI49_2764	NP_015267.1	33.4	8.2e-205	709.9	NP_015267.1 ATP-binding cassette multidrug transporter PDR12 [Saccharomyces ce
DI49_2764	NP_014796.3	31.8	8.2e-181	630.2	NP_014796.3 ATP-binding cassette multidrug transporter PDR5 [Saccharomyces cer
DI49_2764	NP_014973.1	31.9	2.4e-180	628.6	NP_014973.1 ATP-binding cassette multidrug transporter PDR10 [Saccharomyces ce
DI49_2764	NP_010694.1	31.0	1.6e-168	589.3	NP_010694.1 ATP-binding cassette multidrug transporter PDR15 [Saccharomyces ce
DI49_2764	NP_014567.2	23.5	2.0e-49	193.7	NP_014567.2 uncharacterized protein YOL075C [Saccharomyces cerevisiae S288C]

BLAST結果からベストヒットを抽出する

```
% sort -k 1,1 -u -s blastout.tab > blasttop.tab
```

第1フィールド（クエリ配列）をキーとしてソートし（-k 1,1）、キーが重複した場合は最初の行のみを出力（-u ユニーク）。元の並びがクエリ配列ごとにE-value（スコア）の順になっており、-s（安定ソート）を指定することで、その順を維持したままソート・ユニークが実行されるため、ベストヒット1つのみが出力される。

ソートキー（クエリ）

E-value

Score

DI49_1142	NP_009669.1	93.421	228	15	0	8	235	4	231	9.83e-162	444	ADP-ribose diphosphatase
DI49_2764	NP_012252.1	88.604	1404	156	3	1	1401	1	1403	0.0	2560	ATP-binding cassette multid
DI49_2764	NP_014654.1	67.521	1404	426	8	1	1393	1	1385	0.0	1943	ATP-binding cassette sterol
DI49_2764	NP_014468.3	37.097	1364	721	26	51	1356	48	1332	0.0	873	ATP-binding cassette multid
DI49_2764	NP_014468.3	22.911	694	426	27	762	1402	43	680	2.40e-27	119	ATP-binding cassette multid
DI49_2764	NP_014468.3	20.819	562	377	20	111	639	807	1333	3.47e-17	85.9	ATP-binding cassette multid
MSTRG.1000.1	NP_013901.1	68.702	1425	423	7	1	1416	1	1411	0.0	2005	Ecm5p [Saccharomyces cerevi
MSTRG.1000.1	NP_012653.1	34.177	79	51	1	485	562	384	462	5.68e-05	45.4	histone demethylase [Saccha
MSTRG.1000.1	NP_012653.1	27.523	109	73	3	637	743	487	591	5.54e-04	42.4	histone demethylase [Saccha
MSTRG.1000.3	NP_013901.1	68.702	1425	423	7	1	1416	1	1411	0.0	2005	Ecm5p [Saccharomyces cerevi
MSTRG.1000.3	NP_012653.1	34.177	79	51	1	485	562	384	462	5.68e-05	45.4	histone demethylase [Saccha
MSTRG.1000.3	NP_012653.1	27.523	109	73	3	637	743	487	591	5.54e-04	42.4	histone demethylase [Saccha

双方向ベストヒットの抽出

各クエリ配列に対するベストヒットの出力（前出）

```
% sort -k 1,1 -u -s blastout.tab > blast_top.tab
```

逆方向（データベース配列）から見たベストヒットの出力



```
% sort -k 2,2 -k 11,11g -k 12,12nr blastout.tab | sort -k 2,2 -u -s  
    > blast_top_rev.tab
```

双方向ベストヒット（オーソログの推定）の出力

```
% sort blast_top.tab blast_top_rev.tab | uniq -d > blast_bbh.tab
```

（両方向のベストヒットを合わせてソートし、重複した行を出力する (uniq -d)。どちらの方向から見たベストヒットにも含まれるペアが出力される）

InterProScan モチーフ／ドメイン検索



InterProScan の実行

query.faをクエリとして、InterProのデータベース全てを対象として検索。
検索結果にはGO termも含める。

```
% interproscan.sh -i query.fa -b iprout -goterms --cpu 4
```



```
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 Pfam PF01680 SOR/SNZ family 4 211 3.5E-103 ..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 ProSiteProfiles PS51129 PdxS/SNZ family profile. 6 298 150 ...
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 Gene3D G3DSA:3.20.20.70 1 298 7.8E-137 ..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 TIGRFAM TIGR00343 TIGR00343: pyridoxal 5'-phosphate syntha..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 PIRSF PIRSF029271 1 298 1.9E-143 ..
```

検索結果からGO termの抽出

```
% cut -f1,14 seub_genes6.iprscan.tsv
```

```
XM_018368617.1
XM_018368617.1 GO:0042819|GO:0042823
XM_018368617.1 GO:0003824
XM_018368617.1 GO:0042819|GO:0042823
XM_018368617.1 GO:0042819|GO:0042823
```

ファミリー／ドメインアノテーションの複雑さ



検索結果は各配列に一つではなく、ドメイン単位でつけられるもの、ドメインはオーバーラップしているが、ファミリーの大きさが異なるものなどが含まれる。

ホモロジーに基づくアノテーションの戦略


- 近縁種で、高品質なアノテーションがついたモデル生物ゲノムが利用可能な場合——そのゲノムに対するオーソログを同定し、アノテーションをコピーする。
- 特にターゲットとする生物種を絞らず、幅広い生物種から情報を集めたい場合——nrなどの網羅的なデータベースを検索して上位のヒットのアノテーションをコピーする。
- ホモロジー検索だけでは類似性が低い配列しかヒットせず、信頼性が低い場合——InterProなどのモチーフデータベースの検索を併用する。

テキスト記述によるアノテーションの問題点


- 基本的に遺伝子（タンパク質）の名前を記載しただけで、具体的な機能について記載しているわけではない。
- 生物学的な解釈を考えるには、各遺伝子の機能に関する知識が別途必要になる。
- 大規模なRNA-seq解析結果を解釈するには、この部分についても計算機のサポートが必要。

Gene Ontology (GO)

機械可読な遺伝子機能の表現





包含関係を表すグラフ：有向非巡回グラフ Directed Acyclic Graph (DAG)



GO階層のグラフ

- 各ノードはGO termを表す
 - 最上位ノードは以下の3種類
 - biological process
 - molecular function
 - cellular component
- 各矢印（エッジ）はGO term間の関係を表す
 - 包含関係を表す矢印は2種類
 - is_a AはBの一種である
 - part_of AはBの一部である
 - その他の関係を表す矢印
 - regulates
 - occurs_in など



GO annotation

既知遺伝子へのGO termの割り当て


- GOアノテーションデータベース
 - モデル生物ゲノムデータベース
 - MGI (マウス)
 - FlyBase (ショウジョウバエ)
 - TAIR (シロイヌナズナ)
 - SGD (酵母) など
 - 網羅的なデータベース
 - タンパク質配列データベースUniProt
 - モチーフドメインデータベースInterPro
 - パスウェイデータベースReactome など
- アノテーションの根拠をEvidence Codeで示す

Human IKBKB gene に対するGO アノテーション

☐	Gene/product	Gene/product name	Annotation qualifier	GO class (direct)	Annotation extension	Contributor	Organism	Evidence	Evidence with	PANTHER family	Type	Isoform	Reference	Date
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		stimulatory C-type lectin receptor signaling pathway		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-5621481	20181121
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		antigen processing and presentation of exogenous peptide antigen via MHC class I, TAP-dependent		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-1236974	20180419
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		MyD88-independent toll-like receptor signaling pathway		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-168927	20171201
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:20434986	20100804
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:15084260	20151001
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	EXP		ikb kinase pthr22969	protein		PMID:18692471	20170505
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	EXP		ikb kinase pthr22969	protein		PMID:23613522	20170505
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:25326418	20200702
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		CACAO	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:25636800	20151001
☐	IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-168140	20170811
☐	IKBKB	Inhibitor of nuclear factor kappa-B		protein serine/threonine kinase activity		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-202541	20150207

Evidence Code

GO Evidence Code Decision Tree



- IEA (Inferred from Electronic Annotation) は計算機による予測のみなので要注意！
- ND (No Data)は、証拠がないことが確認されているので、さらに信頼性が低い

Note on use of ND evidence code:

Unlike the other evidence codes, the No Data (ND) code does not indicate evidence or a method from a specific reference. Rather, it indicates that the annotator looked at the available information and determined that nothing is known about the gene for a given aspect of GO (molecular function, biological process, or cellular component). The annotator will always look at all available literature for the gene. Depending on the resources and annotation philosophy of the annotating group, the annotator may also look at sequence comparison data to determine if any predictions may be made based on the sequence.

ホモロジーに基づくアノテーションの戦略（再掲）

- 近縁種で、高品質なアノテーションがついたモデル生物ゲノムが利用可能な場合——そのゲノムに対するオーソログを同定し、アノテーションをコピーする。
- 特にターゲットとする生物種を絞らず、幅広い生物種から情報を集めたい場合——nrなどの網羅的なデータベースを検索して上位のヒットのアノテーションをコピーする。
- ホモロジー検索だけでは類似性が低い配列しかヒットせず、信頼性が低い場合——InterProなどのモチーフデータベースの検索を併用する。

GOを用いてアノテーションする場合、GOアノテーションのついたデータベースを検索して、その結果に基づいてGO termをコピーすればよい。ただし、アノテーションのクオリティを考慮すると、2番めのケースは特に注意が必要。

ホモロジーに基づくGOアノテーション


- 類似性検索でトップヒットのGOを採用すれば良いとは限らない。

→スコアが同程度なら、エビデンスコードを考慮して、より信頼性の高いアノテーションを採用した方がよい。

- あるGO termがアサインされる場合、その上位のGO termも必ずアサインされる。

→アノテーションとしては、その遺伝子に当てはまる最も下位のGO termを記載する。

Hit	Score	GO	Evidence
Gene-A	90	GO-2	IEA
Gene-B	85	GO-2	IDA
Gene-C	80	GO-3	IDA
Gene-D	60	GO-4	IEA



BLAST2GO

- Annotation Score: $AS = DT + AT$
- $DT = \max(\text{similarity} \times ECw)$
ECw: Evidence Code weight
- $AT = (\#GO - 1) \times GOw$
#GO: number of child GOs assigned
GOw: GO weight (user defined parameter)
- $AS \geq \text{threshold}$ を満たす最下層のGOをアサインする


Evidence code weight

EC	Description	Default
IDA	Inferred from direct assay	1
IMP	Inferred from mutant phenotype	1
IGI	Inferred from genetic interaction	1
IPI	Inferred from physical interaction	1
IEP	Inferred from expression pattern	1
TAS	Traceable author statement	0.9
NAS	Non-traceable author statement	0.9
IC	Inferred by curator	0.9
ISS	Inferred from sequence or structural similarity	0.9
RCA	Inferred from reviewed computational analysis	0.9
IEA	Inferred from electronic annotation	0.7
ND	No biological data available	0.5
NR	Not recorded	0.5

Götz et al. (2008) Nucl.Acids.Res. 36, 3420

→Omixonという有償ソフトへ統合化

EggNOG Mapper オーソログベースのアノテーション




- あらかじめデータベース中の配列をオーソロググループに分類し、各グループの系統樹を作成。
- クエリ配列に対するホモロジー検索により seed ortholog 配列を同定し、さらに系統樹を用いて他生物種におけるオーソログを同定する。
- seed ortholog に対する類縁関係を考慮し、近縁種のオーソログに付けられた機能アノテーションをコピーする。


オーソロググループ・系統樹

Infer fine-grained orthologs

eggNOG OG & phylogenetic tree



アノテーション



EggNOG mapper の実行

DIAMONDを用いて、EggNOG mapperの実行

```
% emapper.py -i query.fa -o outname -m diamond --cpu 6
```

アノテーション結果から、テキスト記述を抽出

```
% cut -f1,8 outname.emapper.annotations
```

```
#query Description
XM_018368616.1 expression is induced before the diauxic shift and also in the absence of thiamin
XM_018368617.1 Belongs to the PdxS SNZ family
XM_018368618.1 member of a subtelomeric gene family including THI5 THI11 THI12 and THI13
XM_018368619.1 siderophore-bound iron prior to uptake by transporters
XM_018368620.1 involved in the retention of siderophore-iron in the cell wall
```

アノテーション結果から、アサインされたGOのリストを抽出


```
% cut -f1,10 outname.emapper.annotations
```

```
#query GOs
XM_018368616.1 GO:0003674,GO:0003824,GO:0004359,GO:0005575,GO:0005622,GO:0005623,GO:0005737,GO:0005829,GO:0006081,...
XM_018368617.1 GO:0000096,GO:0000097,GO:0003674,GO:0003824,GO:0003922,GO:0005575,GO:0005576,GO:0006082,GO:0006520,...
XM_018368618.1 GO:0003674,GO:0003824,GO:0006725,GO:0006766,GO:0006767,GO:0006772,GO:0006790,GO:0006807,GO:0008150,...
XM_018368619.1 GO:0000041,GO:0000293,GO:0000322,GO:0000323,GO:0000324,GO:0000329,GO:0003674,GO:0003824,GO:0005575,...
XM_018368620.1 GO:0000322,GO:0000323,GO:0000324,GO:0005575,GO:0005618,GO:0005622,GO:0005623,GO:0005737,GO:0005773,...
```

バージョン等によってカラム位置は違う可能性がある所以要確認

GO enrichment 解析

- 発現量が増加／減少した遺伝子群において、より多く出現する（エンリッチしている）機能(GO term)を抽出する。
- まず設定した閾値（有意水準）によって遺伝子セットを抽出し、その中でエンリッチメント解析を行うアプローチと、スコアの並び順を用いてエンリッチメント解析を行うアプローチがある。



Overrepresentation Analysis (Fisher's exact test)

一組のトランプから10枚のカードを抜き出したとき、赤札（ハート、ダイヤ）が5枚、絵札（JQK）が4枚含まれていた。このとき、赤札と絵札のどちらがよりエンリッチ（濃縮）していると言えるか？

2♠ 3♣ 5♠ 6♥ 6♦ 8♠ J♦ Q♦ Q♣ K♦

赤札 5 枚
全体 $26/52 = 0.5$
手札 $5/10 = 0.5$
 $p=0.6368$

絵札 4 枚
全体 $12/52 = 0.23$
手札 $4/10 = 0.4$
 $p=0.2492$

ダイヤの絵札 3 枚
全体 $3/52 = 0.058$
手札 $3/10 = 0.3$
 $p=0.00543$

分割表

	絵札	数札	計
手札	4	6	10
残り	8	34	42
計	12	40	52

Fisher's exact test (正確確率検定)

N 枚のカード中に n 枚の「当たり」が含まれるとき、そこから m 枚を抜き出した中に「当たり」が k 枚以上(または以下)含まれる確率を求める。

→超幾何分布(Hypergeometric distribution)で計算できる


$$P(k; n, m, N) = \frac{\binom{n}{k} \binom{N-n}{m-k}}{\binom{N}{m}}$$

Rでの計算

```
> tab <- matrix( c(4,8,6,34), 2, 2 )  
> fisher.test(tab,  
               alternative='greater')
```


Overrepresentation Analysis (Fisher's exact test)

発現上昇した遺伝子セット800個のうち、60個にあるGO termが付けられていた。ゲノム全体10000遺伝子のなかで、そのGO termが付けられた遺伝子は500個であった。このGO termは発現上昇した遺伝子セット中で過剰出現していると言えるか？
発現上昇した遺伝子数が1000個であった場合はどうか？



分割表

	機能を持つ	機能を持たない	計
発現上昇あり	60	740	800
発現上昇なし	440	8760	9200
計	500	9500	10000

→ Fisherの正確確率検定 (Fisher's exact test)

```
fisher.test( matrix( c(60, 440, 740, 8760), 2, 2), alternative='greater' )
```

p=0.00089


(発現上昇した遺伝子が1000個の場合)

```
fisher.test( matrix( c(60, 440, 940, 8560), 2, 2), alternative='greater' )
```


p=0.076

結果が発現差
解析の閾値に
依存


Gene Set Enrichment Analysis (GSEA)



- 全遺伝子を発現解析の結果に基づいてソートし、その並び順の中で、対象とする遺伝子セットの出現が、偏りのない分布（一様分布）からずれているかを判定する（Kolmogorov-Smirnov検定）。
- カウントを、ソートに用いた指標で重み付けすることにより、上位/下位のヒットにより大きな重みを与えることもできる。



GO enrichment 解析とGO階層




- GO enrichment解析では、全てのGO termについてenrichment testを繰り返す。
- GO階層の下位ノードにアサインされた遺伝子は上位ノードにも自動的にアサインされるため、上下ノードに依存関係が生じる。

→有意なGO termは、GO階層上近傍に集まって出現することが多い。

→上位ノードは分母が大きくなるため、「濃縮度」は低くなる。

Rを用いたGO enrichment 解析

- clusterProfiler
 - GOのほか、KEGGやDisease Ontology(DO)など、様々なデータベースに対応
 - 結果を可視化するツールが充実している
- TopGO
 - 隣接するGO階層間で生じる冗長性を排除するアルゴリズムを実装
 - 様々な統計手法とアルゴリズムを組み合わせ、enrichment解析を行う汎用的な枠組みを提供



入力データの準備

```
# edgeRのデータオブジェクト (DGEList) から解析結果全体をテーブルとして抜き出す
etab <- topTags(DGEList, n=999999)$table
```

Fisher's exact testの入力： 発現変動遺伝子のリストと全遺伝子のリスト

```
# FDRが0.01以下で、かつ2倍以上 (logFC>1) 発現上昇した遺伝子を抽出
upreg <- subset(etab, logFC > 1.0 & etab$FDR < 0.01)
# 発現上昇した遺伝子と全体の遺伝子名リストを作成
upregGenes <- rownames(upreg)
allGenes <- rownames(etab)
```

GSEAの入力： 発現変動の程度に応じてソートされたスコアリスト

```
# -log(FDR) にlogFCの符号をかけてup/downを区別した指標を算出
expScore <- sign(etab$logFC) * -log(etab$FDR)
# expScoreの各値にnameとして遺伝子名を対応づけ、昇順にソートする
names(expScore) <- rownames(etab)
expScore <- sort(expScore, decreasing=TRUE )
```

GOアノテーションの準備

公開されたアノテーションデータベースの利用1

OrgDb

- 代表的モデル生物種の遺伝子データベースでGOのアノテーションを含む。
- org.<Sp>.<id>.db という名称のパッケージとして公開。ヒトorg.Hs.eg.db、マウスorg.Mm.eg.dbなど、<id>=eg (Entrez Gene)のものを中心に現在約20種類。
- enrichment解析に用いるには、発現解析に用いた遺伝子IDが、NCBI GeneIDなど、このデータベースに登録されたIDのいずれかと一致する必要がある。
- キー（遺伝子ID）とカラム（抽出数r遺伝子属性）を指定して情報を取り出す。

```
> library(org.Mm.eg.db)
# マウス用データベース。ロードすると、org.Mm.eg.db という名前のオブジェクトを介してデータベースにアクセスできる
# 利用可能な属性の一覧を表示
> columns(org.Mm.eg.db)
[1] "ACCNUM"      "ALIAS"      "ENSEMBL"    "ENSEMBLPROT" "ENSEMBLTRANS"
[6] "ENTREZID"    "ENZYME"     "EVIDENCE"    "EVIDENCEALL"  "GENENAME"
[11] "GO"          "GOALL"      "IPI"         "MGI"          "ONTOLOGY"
[16] "ONTOLOGYALL" "PATH"       "PFAM"        "PMID"         "PROSITE"
[21] "REFSEQ"      "SYMBOL"     "UNIGENE"     "UNIPROT"
# SYMBOLが "KRAS" である遺伝子のGOを表示
> select(org.Mm.eg.db, keys="Kras", keytype="SYMBOL", columns="GO")
  SYMBOL      GO EVIDENCE ONTOLOGY
1   Kras GO:0000166      IEA      MF
2   Kras GO:0001934      ISO      BP
3   Kras GO:0003924      IGI      MF
```

GOアノテーションの準備

公開されたアノテーションデータベースの利用2

AnnotationHub

- より多くの生物種のアノテーションを集積。必要なものをダウンロードして使う。“OrgDb”として登録されたものは前項のOrgDbデータベースと同様に使える。

```
> library(AnnotationHub)
# AnnotationHubへのアクセスインターフェイスを変数ahに格納
> ah <- AnnotationHub()
# イネ(Oryza sativa)を検索。Queryコマンドの2番目の引数は、任意の数のキーワードをベクトルとして与える。
> query(ah, c("OrgDb", "oryza sativa"))
AnnotationHub with 3 records # <- ヒットが3つ見つかっている
# snapshotDate(): 2022-04-25
...
# retrieve records with, e.g., 'object[["AH101066"]]' # <- データへのアクセス方法。objectは変数名ahに置き換える
# title # 以下、ヒットしたデータの一覧
AH101066 | org.Oryza_sativa_(japonica_cultivar-group).eg.sqlite
AH101067 | org.Oryza_sativa_Japonica_Group.eg.sqlite
AH101068 | org.Oryza_sativa_subsp._japonica.eg.sqlite
# データをダウンロードし、org.os.dbという変数に格納
> org.os.db <- ah[["AH85565"]]
> columns(org.os.db)
"ACCNUM" "ALIAS" "CHR" "ENTREZID" "EVIDENCE" "EVIDENCEALL" "GENENAME" "GID" "GO"
"GOALL" "ONTOLOGY" "ONTOLOGYALL" "PMID" "REFSEQ" "SYMBOL"
```

clusterProfilerによる解析

Fisher's exact testの実行: enrichGO

```
# 入力：発現変動遺伝子 upregGenes, 全体遺伝子 allGenes, アノテーション org.Mm.eg.db
```

Biological Process (BP)を対象として実施。遺伝子の検索キーはENSEMBL

```
> cprof.up.bp.fisher <- enrichGO(gene=upregGenes, universe=allGenes,
  OrgDb=org.Mm.eg.db, ont="BP", keyType="ENSEMBL",
  pvalueCutoff=0.01)
```


Gene Set Enrichment Analysisの実行: gseGO

入力：発現変動に基づくソート済みリスト expScore, アノテーション org.Mm.eg.db


```
> cprof.bp.gsea <- gseGO(geneList=expScore, OrgDb=org.Mm.eg.db, ont="BP",
  keyType="ENSEMBL", pvalueCutoff=0.1)
```


解析結果の可視化(Fisher's exact test)

```
> library(enrichplot)
> barplot(cprof.up.bp.fisher, showCategory=10)
```




```
> goplot(cprof.up.bp.fisher, showCategory=10)
```



解析結果の可視化(Fisher's exact test)

```
# org.Mm.eg.db データベースを使って、 ENSEMBL IDから可読性の高い名前に変換する
> cprof.up.bp.fisher <-setReadable(cprof.up.bp.fisher, 'org.Mm.eg.db', "ENSEMBL")
> cnetplot(cprof.up.bp.fisher)
```



```
> upsetplot(cprof.up.bp.fisher)
```



解析結果の可視化(Gene Set Enrichment Analysis)

```
> ridgeplot(cprof.bp.gsea)
gseaplot(cprof.bp.gsea, geneSetID=1)
```


>



ユーザアノテーションの利用 1

オーソログ解析に基づくアノテーション

- 近縁のモデル生物の遺伝子に対するオーソログ対応づけができている場合、それによってモデル生物のアノテーションを対応づけてGO解析を行うことができる。



ユーザアノテーションの利用 2

遺伝子-GO対応表の取り込み

- 遺伝子ごとのGO termのアサインができている場合、それを直接読み込んで解析する。
- clusterProfilerでは、以下のいずれかの形式で遺伝子とGOの対応表を準備する。

GMT 形式

GO-1	GOname1	gene1	gene2	gene3
GO-2	GOname2	gene4	gene5	

`read.gmt(gmfile)` で読み込む。
GOnameを読み飛ばして、右の形式と同じ
データフレームを生成する。

または、以下の形式

GO-1	gene1
GO-1	gene2
GO-1	gene3
GO-2	gene4
GO-2	gene5

`read.delim(file)` で読み込む

- clusterProfilerでは、GO ID とその名前の対応表(TERM2NAME)も用意する必要がある。

GO-1	GOname1
GO-2	GOname2

clusterProfilerによる解析(対応表を読み込む)

遺伝子とGOID対応表の読み込み

```
> go2gene <- read.gmt("go2gene.gmt")
```

祖先ノードに遡ってGOをアサインする

```
> go2gene.expand <- biuldGMap(go2gene)
```

TERM2NAMEの対応表をGO.dbから作成する

```
> gonames <- select(GO.db, keys=keys(GO.db), columns="TERM")
```

Fisher's exact testの実施 (enricher)

```
> cprof.fisher2 <- enricher(gene=upregGenes, TERM2GENE=go2gene.expand,  
                           TERM2NAME=gonames)
```

Gene Set Enrichment Analysisの実施 (GSEA)

```
> cprof.gsea2 <- GSEA(geneList=expScore, TERM2GENE=go2gene.expand  
                    TERM2NAME=gonames)
```